

Relazione di Serie Temporal

1. Selezione del dataset

Il dataset selezionato, reperito dal sito finance.yahoo.com¹, contiene variabili relative all'andamento dei prezzi e dei volumi di vendita delle azioni di Tesla:

- date: data nel formato anno-mese
- open: prezzo di apertura al primo giorno del mese di una singola azione (in \$)
- high: prezzo massimo raggiunto nel mese di una singola azione (in \$)
- low: prezzo minimo raggiunto nel mese di una singola azione (in \$)
- close: prezzo di chiusura all'ultimo giorno del mese di una singola azione (in \$)
- adj-close: prezzo di chiusura aggiustato per gli splits² e le distribuzioni dei dividendi e/o del capitale guadagnato (in \$)
- volume: numero di azioni vendute nel mese

Si nota come le variabili close e adj-close abbiano gli stessi valori.

2. Selezione del periodo temporale in cui studiare la serie

Il periodo temporale in cui viene studiata la serie parte da gennaio 2011 e arriva a dicembre 2022: i dati disponibili partono da giugno 2010 (data in cui Tesla è stata quotata in borsa) fino ad oggi, ma si è scelto di eliminare i mesi del 2010 e del 2023, in modo tale da avere per ogni anno i dati di ogni singolo mese.

3. Selezione delle variabili di cui studiare la serie

Dai boxplot in figura 1, si osserva come le variabili open, high, low, close e adj-close abbiano un grafico simile: il box è schiacciato verso il basso, la quasi totalità dei valori è inferiore a 100\$ ed oltre il 50% inferiore a 50; inoltre, in tutti e cinque i casi è presente un elevato numero di outliers verso valori più alti. Per quanto riguarda la variabile volume, si osserva una maggiore dispersione dei dati: si va da un minimo di circa $2.6 \cdot 10^8$ azioni vendute, ad un massimo di all'incirca $7.1 \cdot 10^9$, con una mediana approssimativamente di $2 \cdot 10^9$.




Figura 1 – Boxplot

Anche dagli istogrammi (figura 2), si rileva come le variabili relative ai prezzi delle azioni abbiano una distribuzione simile: la maggior parte dei valori per mese e anno sono inferiori a 50\$; si riscontrano alcune differenze tra i valori massimi di high e low rispetto alle altre variabili: nella prima si possono osservare valori più alti (oltre 400\$), mentre nell'altra più bassi (inferiori ai 350\$); open, close e adj-close, invece, hanno tutte valori massimi intorno a 400\$. Dall'istogramma di volume si constata nuovamente come vi sia più variabilità rispetto alle altre variabili, con la maggior parte dei valori concentrati in una quantità di azioni vendute inferiore a $3 \cdot 10^9$, per poi esserci una diminuzione delle unità all'aumentare del numero di azioni vendute.

¹<https://finance.yahoo.com/quote/TSLA/history?period1=1293840000&period2=1672444800&interval=1mo&filter=history&frequency=1mo&includeAdjustedClose=true>

²Split: frazionamento azionario attraverso il quale una società aumenta il numero di azioni in circolazione senza alterare il capitale sociale al fine di garantire una maggiore liquidità al titolo




Figura 2 – Istogrammi

Dall'andamento per anno delle variabili open, close, high, low e adj-close (figura 3), si evidenzia ancora una volta come il trend sia simile: una piccola crescita dal 2013 al 2014, stabilità fino al 2020 e aumento rilevante tra il 2020 ed il 2022. L'andamento del numero di azioni vendute, invece, subisce una crescita notevole dal 2013 al 2014, con un successivo calo nel 2015, per poi avere oscillazioni con un picco tra il 2020 ed il 2021 e poi ritornare all'incirca sui valori precedenti.




Figura 3 – Andamenti per anno

Dalle analisi svolte si conclude che le variabili open, close, low, high e adj-close abbiano distribuzione e andamento molto simile a differenza della variabile volume. Si sceglie quindi di studiare le serie relative alle variabili high e volume.

4. Studio serie storica high

Come primo passo per lo studio della serie è stata effettuata una trasformazione di Box-Cox per stabilizzare la varianza. Il valore ottimale di lambda ottenuto è $4.102 \cdot 10^{-5}$; dato che tale numero è circa zero, la trasformazione della serie è quasi analoga alla trasformazione logaritmica: di conseguenza vengono accentuate le differenze piccole (nel 2013) e vengono ridotte quelle grandi (nel 2020), visibili in figura 4.




Figura 4 – Andamento high Box-Cox

Per verificare se la serie trasformata presenta autocorrelazione si analizzano i diagrammi di lag, in cui vengono tracciate le dispersioni tra la serie e quella ritardata di un determinato lag (in mesi). Si esaminano le serie ritardate da 1 a 12 mesi: si può notare come all'aumentare del lag, la serie si discosti sempre di più da quella originale; inoltre, in tutti i diagrammi sono presenti tre nuvole di punti sulla bisettrice, corrispondenti all'inizio, alla metà e alla fine del periodo di studio. Si può concludere che non è presente periodicità mensile. Dall'osservazione del seasonal-plot, si conferma l'assenza di variazioni stagionali.




Figura 5 – Diagrammi di lag e seasonal plot high Box-Cox

Per ottenere una serie stazionaria viene usato il metodo delle differenze: calcolando le differenze prime si ottiene già una serie stazionaria e analizzando i diagrammi di lag non si nota nessuna autocorrelazione.





Figura 6 – Andamento e diagrammi di lag differenze prime – high

Dai qq-plot in figura 7, si analizzano le distribuzioni della serie temporale originale, della serie trasformata con Box-Cox e con le differenze prime: si osserva come quest'ultima serie assuma una distribuzione quasi normale, a differenza delle altre due.




Figura 7 – Q-Q plot

Dal grafico di autocorrelazione della serie originale high, si nota un decremento all'aumentare del lag, ciò suggerisce di usare le differenze prime: dall'ACF si rileva come l'unico lag al di fuori delle bande sia corrispondente al valore 1. Per quanto riguarda l'autocorrelazione parziale, dal correlogramma si osserva, anche in questo caso, che l'unico valore a superare la soglia corrisponda al lag 1. Si ipotizza quindi un modello ARIMA(1,1,1). La funzione Rstudio `auto.arima()` fornisce invece il modello ARIMA(0,1,1), ossia una modello MA(1).




Figura 8 – Correlogrammi

Confrontando l'indice AIC in tabella 1 per i due modelli, risulta migliore l'ARIMA(0,1,1), con coefficiente stimato di 0.1867.

	ARIMA(0,1,1)	ARIMA(1,1,1)
AIC	1258.85	1260.57

Tabella 1 - Confronto modelli high

Analizzando i residui del processo ARIMA(0,1,1), si osserva nei correlogrammi relativi all'autocorrelazione ed autocorrelazione parziale, nel plot e nei diagrammi di lag (Figura 9) una dispersione apparentemente randomica.




Figura 9 – Analisi dei residui arima(0,1,1)

Effettuando due previsioni del valore di high nei successivi due anni, una all'80% ed una al 95%, risulta, nella prima, un intervallo di valori che va da 167.04 a 217.10\$ a gennaio 2023, fino ad arrivare a dicembre 2024 ad una fascia da 47.44 a 336.71\$. Per la previsione al 95% gli intervalli sono più ampi: 153.79 ÷ 230.36 e -29.13³ ÷ 413.28. Si sottolinea come al passare del tempo gli intervalli di predizione del valore siano più grandi.




Figura 10 – Previsione high

³ Il prezzo di un'azione non può essere negativo, per cui bisognerebbe considerare il valore come zero. Il valore riportato è quello fornito dalla funzione `forecast()`.

5. Studio serie storica volume

Analogamente alla serie su high, viene effettuata una trasformazione di Box-Cox; si ottiene nuovamente un valore di lambda vicino a zero ($4.102 \cdot 10^{-5}$). Viene quindi accentuato l'incremento tra il 2013 ed il 2014, mentre le differenze osservate precedentemente sulla serie originale vengono meno evidenziate.




Figura 11 – Andamento volume Box-Cox

Dai diagrammi di lag, si evince come nei primi ritardi solo pochi punti si discostino dalla retta, mentre all'incrementare del lag questi aumentino. Inoltre, nei ritardi più elevati, la nuvola di punti intorno alla retta è molto più dispersiva rispetto ai primi: non si rileva quindi una periodicità mensile. Questo fatto è confermato anche dal seasonal plot: infatti, la serie relativa alla variabile volume trasformata non presenta alcuna traccia di stagionalità nei mesi.




Figura 12 – Diagrammi di lag e seasonal plot volume Box-Cox

Dal calcolo delle differenze prime si ottiene una serie stazionaria; dall'osservazione dei diagrammi di lag ottenuti non si riscontra alcuna autocorrelazione.




Figura 13 – Andamento e diagrammi di lag differenze prime - volume

Dai qq-plot (figura 14), si confronta l'adattamento ad una distribuzione normale delle serie relative a volume originale, trasformata con Box-Cox e con le differenze prime: si evidenzia che quest'ultima ha una distribuzione all'incirca gaussiana, al contrario delle altre due.




Figura 14 – Q-Q plot

Si osserva una situazione simile a quanto visto per la variabile high: un decremento nell'autocorrelazione all'aumentare del lag nella serie originale, che porta ad utilizzare le differenze prime. Sia nell'ACF che nel PACF si rileva come l'unico valore a superare la soglia corrisponda al lag 1. I grafici quindi suggeriscono un processo ARIMA(1,1,1). La funzione Rstudio auto.arima(), propone invece il modello ARIMA(0,1,0), ossia una random walk.




Figura 15 – Correlogrammi

Dal confronto dell'indice AIC in tabella 2, si nota come sia migliore per il processo ARIMA(1,1,1).

	ARIMA(0,1,0)	ARIMA(1,1,1)
AIC	6272.55	6262.5

Tabella 2 - Confronto modelli volume

Confrontando i grafici dei residui (figura 16 ARIMA(0,1,0) e figura 17 ARIMA(1,1,1)), emerge come l'ARIMA(1,1,1) sia preferibile, in quanto la distribuzione sembra essere più casuale.




Figura 16 – Analisi dei residui arima(0,1,0)




Figura 17 – Analisi dei residui $\text{ARIMA}(1,1,1)$

Si sceglie quindi di utilizzare per le previsioni il processo $\text{ARIMA}(1,1,1)$.

Si effettuano le stesse previsioni fatte per high: all'80% si va da una fascia $1.6 \div 3.6$ miliardi circa a gennaio 2023 fino ad una $-46 \text{ milioni}^4 \div 5.3$ miliardi di azioni di vendite a dicembre 2024. Per la previsione al 95% le fasce sono $1.1 \div 4.1$ miliardi e $-1.9 \div 6.8$ miliardi. Anche in questo caso le fasce si espandono al passare del tempo.




Figura 18 – Previsione volume

6. Confronto tra le due serie analizzate

Confrontando le serie storiche high e volume, dalle analisi effettuate precedentemente, si notano alcune differenze: high rimane circa stazionaria fino al 2020, mentre volume fino al 2013; inoltre, high assume un trend non decrescente dal 2011 al 2022, mentre volume ha un trend molto altalenante. In figura viene riportato il grafico delle autocorrelazioni incrociate, per individuare un'eventuale relazione tra le due serie. Si può notare che la correlazione tra high e volume senza ritardi sia ritenuta non significativa. Correlazioni più evidenti si hanno invece tra High e volume con un lag maggiore di 4 mesi.




Figura 19 – Autocorrelazioni incrociate

Indice

1. Selezione del dataset	1
2. Selezione del periodo temporale in cui studiare la serie	1
3. Selezione delle variabili di cui studiare la serie	1
4. Studio serie storica high	2
5. Studio serie storica volume	5
6. Confronto tra le due serie analizzate	7

⁴ Il numero di azioni vendute non può essere negativo, per cui bisognerebbe considerare il valore come zero. Il valore riportato è quello fornito dalla funzione `forecast()`.